



KAUNO TECHNOLOGIJOS UNIVERSITETAS
Informatikos fakultetas

**P170B328 Lygiagretusis
programavimas**

Individualus Projektas

Data: 2019-12-04

Dėstytojai:

lekt. Barisas Dominykas
lekt. Vasiljevas Mindaugas

Studentas:

Justas Milišiūnas

Grupė: IFF-7/2

KAUNAS, 2019

Turinys

Išvadas.....	3
Užduotis.....	3
Sprendimo metodas.....	3
1. Programos aprašymas.....	4
1.1. Metodai.....	4
1.2. Programos pagrindiniai tekstai.....	5
2. Testavimas ir programos instaliavimo bei vykdymo instrukcija.....	6
2.1. Testavimas.....	6
2.2. Programos instaliavimo bei vykdymo instrukcija.....	8
3. Vykdyto laiko kitimo tyrimas.....	9
Išvados.....	13
Literatūra.....	13

Išvadas

Šio projekto tikslas išmokti naudoti lygiagretų programavimą praktikoje. Palyginti kaip programos vykdymo laikas skiriasi naudojant lygiagretinimo principus.

Užduotis

Plokštumoje ($-10 \leq x \leq 10$, $-10 \leq y \leq 10$) išsidėstę n taškų ($3 \leq n$), vienas jų fiksuotas koordinatų pradžioje (0; 0). Kiekvienas taškas su visais kitais yra sujungtas tiesiomis linijomis (stygomis). Raskite tokias taškų koordinates, kad atstumas tarp taškų būtų kuo artimesnis vidutiniam atstumui, o stygų ilgių suma kuo geriau atitiktų nurodytą reikšmę S ($10 \leq S$).

Sprendimo metodas

Ši uždavinį sprendimas:

1. Pradinių taškų susigeneravimas
2. Gradiento paskaičiavimas kiekvienam taškui kiekvienoje iteracijoje
3. Stygų ilgių sumos paskaičiavimas naudojant pradinius taškus
4. Stygų ilgių sumos skaičiavimas naudojant pakeistus taškus pagal gradientą
5. Jeigu suma pagerėja pradiniais taškams priskiriamia pakeistus taškus

Lygiagretinimas buvo padarytas gradiento paskaičiavimo vietoje. Dėl to, kad kiekvienoje iteracijoje reikia paskaičiuoti gradientą kiekvienam taškui. Su dideliu taškų skaičium šią operaciją užtrunka ilgai.

Šio optimizavimo uždavinio lygiagretinimui naudojama Python kalba su procesų paleidimu.

1. Programos aprašymas

1.1. Metodai

`fillWithRandomPoints(min, max, count int) [][]float64`

Šis metodas sugeneruoja duota kiekį taškų koordinačių sistemoje. Priima argumentus min, max ir coun, kurie yra sveikieji skaičiai. Min ir max yra intervalas kuriame taškai turi būti sugeneruoti, count reiškia taškų skaičių. Metodas gražina dvimaty masyvą.

- **generate_points()** - sugeneruoja taškus priklausomai nuo globalaus kintamojo n
- **distance(point1, point2)** - paskaičiuoja atstumą tarp dviejų taškų
- **distance_sum(points)** - paskaičiuoja visų stygų ilgių vidurkį
- **optimize_points(points)** - pagrindinis metodas, kuris kviečia visus kitus metodus. Turi ciklą kur kiekvienoje iteracijoje paskaičiuojamas taškų gradientas. Taškai perstumiami pagal gradientą, lyginamas stygų ilgių vidurkių palyginimas. Vyksta tol kol pasiekia nustatytą iteracijų limitą arba pasiekia nurodyta tikslumą
- **move_by_gradient(gradient_vector, points)** - perstumia taškus pagal gradiento vektorių
- **points_gradient_vector(points, current_sum)** - paskaičiuoja kiekvieno taško gradientą iš kurių susidaro vektorius. Šitame metode padarytas lygiagretinimas
- **point_gradient(i, points, current_sum)** - paskaičiuoja taško pagl duotą indeksą iš taškų masyvo
- **connect_each_point(points)** - sudaro masyvą, kuriame sujungiami visi taškai. Naudojas rezultato grafike norint atvaizduoti stygas jungiančias taškus

1.2. Programos pagrindiniai tekstai

```
def optimize_points(points):
    global alpha
    points = copy.deepcopy(points)
    max_iterations = 1000
    current_sum = distance_sum(points)
    counter = 0
    while counter < max_iterations and alpha >= eps:
        counter += 1
        points_gradient = points_gradient_vector(points, current_sum)
        gradient_norm = [item / np.linalg.norm(points_gradient) for item in
                          points_gradient]
        moved_points = move_by_gradient(gradient_norm, points)
        next_sum = distance_sum(moved_points)
        if next_sum < current_sum:
            points = moved_points
            current_sum = next_sum
        else:
            alpha /= 2
    return points, current_sum, counter + 1
```

Šis metodas bando optimizuoti taškus tol kol pasiekia iteracijų limitą(šiuo atveju 1000) arba taško pakeitimo žingsnis(alpha) tampa mažesniu nei nurodytas limitas(eps=1e-6). Kiekvienoje iteracijoje paskaičiuoja taškų gradientą, perstumia taškus pagal gradientą, paskaičiuoja stygų ilgių vidurkį su pakeistais taškais. Galiausiai palygina tą vidurkį su prieš tai buvusių taškų vidurkiu. Jeigu naujas vidurkis mažesnis tai jis tampa dabartiniu, pakeisti taškai tampa pradiniais taškais. Jeigu vidurkis didesnis tada mažinamas žingsnis(alpha) ir skaičiuojama iš naujo.

```
def points_gradient_vector(points, current_sum):
    gradients = [0.0, 0.0]
    # Gives work to workers pool
    args = partial(point_gradient, points=points, current_sum=current_sum)
    result = pool.map(args, range(1, len(points)))
    # Converts 2d array to 1d
    [gradients.extend(point) for point in result]
    return gradients
```

Šis metodas paskaičiuoja gradientą kiekvienam taškui. Šioje vietoja panaudotas lygiagretumas. Naudojamas iš anksto sukurtas darbuotojų(procesų) pool. Su metodu pool.map darbas paskirstomas kiekvienam darbuotojui tolygiai. Rezultatai iš kiekvieno darbuotojai sustatomi į result masyvą eilės tvarka. Galiausiai tie rezultatai pridedami į gradients masyvą ir grąžinami.

```
def point_gradient(i, points, current_sum):
    # Point's x
    changed_points_x = copy.deepcopy(points)
    changed_points_x[i][0] += h
    # Point's y
    changed_points_y = copy.deepcopy(points)
    changed_points_y[i][1] += h
    return [(distance_sum(changed_points_x) - current_sum) / h,
            (distance_sum(changed_points_y) - current_sum) / h]
```

Šį metodą vykdo darbuotojai. Grąžina paskaičiuota gradiento reiškmę taške.

```
pool = Pool(processes=processes)
```

Šis kodas sukuria procesų pool. Kiekis priklauso nuo globalaus kintamojo processes.

2. Testavimas ir programos instaliavimo bei vykdymo instrukcija

2.1. Testavimas

Testavimas bus atliekamas keičiant globalų taškų skaičiaus kintamąjį n . Galimas taškų optimizavimas labai priklauso nuo pasirinkto taškų generavimo seed.

Skaičiavimams naudojamas 1 procesas

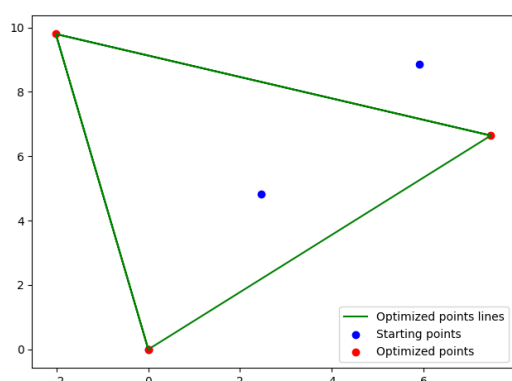
$n = 2$

Primary strings lengths average: **14.509528245867159**

Optimization price: **1.2396533142351218e-05**

Iterations: **97**

Calculated in: **0.06653594970703125s**



pav. 1: Optimizavimo rezultatas kai $n=2$

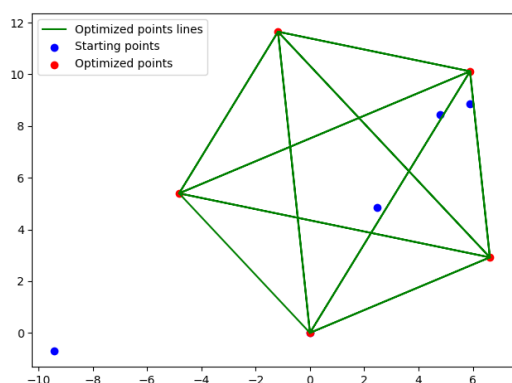
$n=4$

Primary strings lengths average: **55.24274483022175**

Optimization price: **10.557287898603931**

Iterations: **157**

Calculated in: **0.20158982276916504s**



pav. 2: Optimizavimo rezultatas kai $n=4$


$n=8$

Primary strings lengths average: **86.28127016939679**

Optimization price: **41.19682745682422**

Iterations: **275**

Calculated in: **0.9847619533538818s**



*pav. 3: Optimizavimo
rezultatas kai $n=8$*


$n=16$

Primary strings lengths average: **249.25448123470233**

Optimization price: **108.88306848576966**

Iterations: **1001**

Calculated in: **18.299113273620605s**



*pav. 4: Optimizavimo rezultatas kai
 $n=16$*

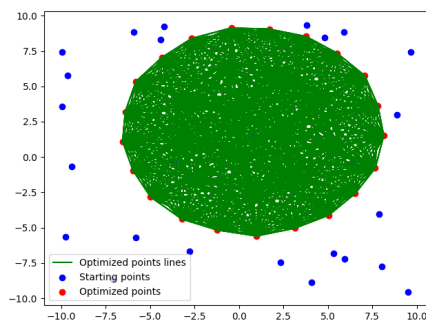
$n=32$

Primary strings lengths average: **494.31034555920826**

Optimization price: **248.50087536719266**

Iterations: **3125**

Calculated in: **318.3662362098694s**



*pav. 5: Optimizavimo
rezultatas kai $n=32$*

Iš šių testų matome, kad pavyko optimizuoti kiekvienu atveju. Tai parodo gauti grafikai bei gautos optimizavimo kainos.

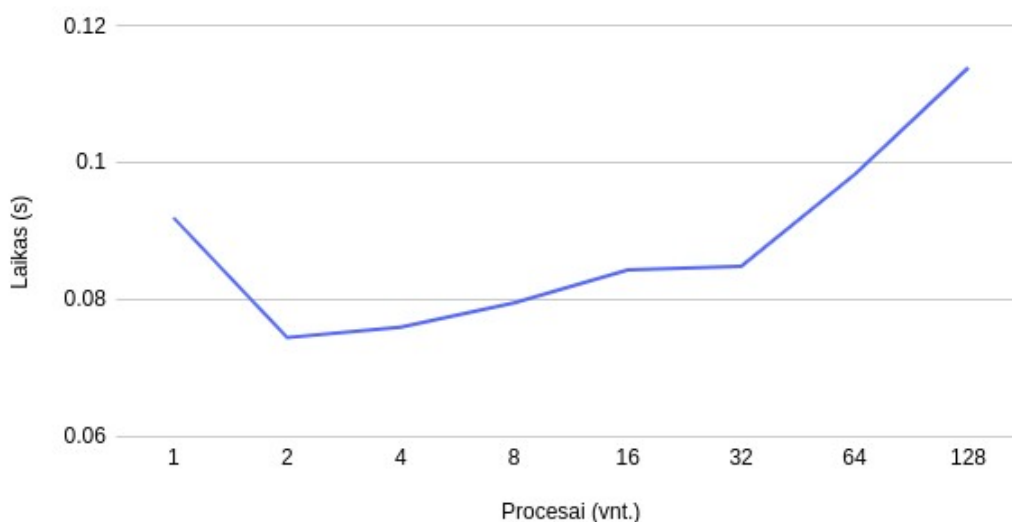
2.2. Programos instaliavimo bei vykdymo instrukcija

Norint pasileisti šią programą reikia parsisiųsti optimization-task.py failą iš moodle arba mano github repositorijos (<https://github.com/Justas-Milisiunas/Lygiagretus-Programavimas/tree/develop/Projektas>). Jeigu naudojama Linux OS, reikia susiinstaliuoti python3 komanda **sudo apt install python3**. Tada reikia susiinstaliuoti matplotlib biblioteką su komanda: **pip3 install matplotlib**. Tada optimization-task.py katalogo vietoje atsidarius terminalą galima paleisti su komanda **python3 optimization-task.py**.

3. Vykdyimo laiko kitimo tyrimas

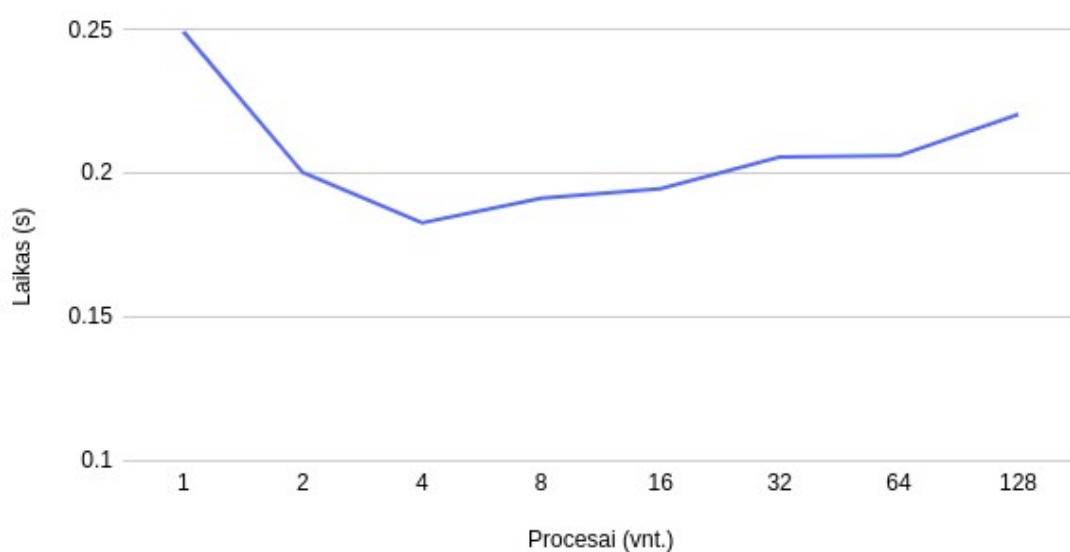
Vykdyimo laiko kitimo tyrimui bus naudojami šie tašku skaičiai: 2, 4, 8, 10, 15, 20. Kiekvienam iš šių takų skaičių bus vykdomas optimizavimas su kiekvienu procesų skaičiumi. Procesai: 1, 2, 4, 8, 16, 32, 64, 128. Rezultatai bus vaizduojami vykdyimo laiko priklausomybe nuo procesų skaičiaus. Grafiko x ašis rodys procesų skaičių, y ašis – vykdyimo laiką.

Vykdyimo laiko priklausomybė nuo procesų skaičiaus su 2 taškais



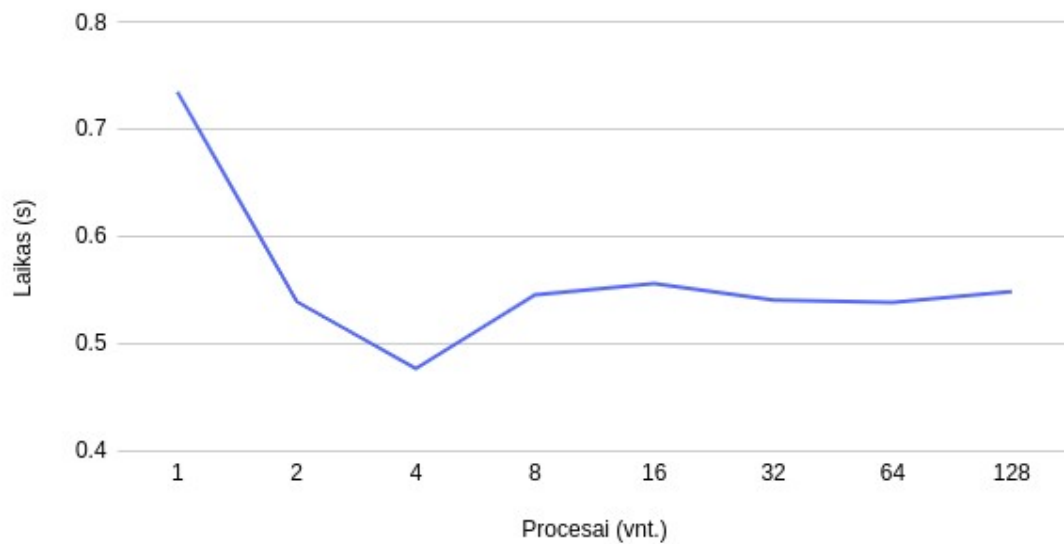
pav. 6: Su 2 taškais

Vykdyimo laiko priklausomybė nuo procesų skaičiaus su 4 taškais




pav. 7: Su 4 taškais

Vykdomo laiko priklausomybė nuo procesų skaičiaus su 6 taškais




pav. 8: Su 6 taškais

Vykdomo laiko priklausomybė nuo procesų skaičiaus 8 taškų




pav. 9: Su 8 taškais

Vykdyimo laiko priklausomybė nuo procesų skaičiaus su 10 taškų




pav. 10: Su 10 taškų

Vykdyimo laiko priklausomybė nuo procesų skaičiaus su 15 taškų



pav. 11: Su 15 taškų

Vykdymo laiko priklausomybė nuo procesų skaičiaus su 20 taškų



pav. 12: Su 20 taškų

Išvados

Individualaus projekto metu buvo lygiagretinama skaitinių algoritmų modulis 2 laboratorinio darbo optimizavimo uždavinio programa. Tikslas buvo pagreitinti programos darbą. Ši programa daugiausia laiko užtrunka skaičiuodami kiekvieno taško gradientą kiekvienoje iteracijoje. Ši vieta ir buvo sulygiagretinama.

Su lygiagretinus, programas pagreitėjo nuo 1.2 iki 2 kartų. Iš tyrimo grafikų matome:

- Labiausia skiriasi vykdymo laikas tarp 1 ir 2 procesų. Su 20 taškų skirtumas siekia net 75 sekundes
- Programa greičiausiai veikia su 4 arba 8 procesais.
- Naudojant daugiau nei 8 procesus programa pradeda letėti. Tai vyksta todėl, kad kompiuteris vienu metu gali vykdyti tik 8 procesus.

Literatūra

1. https://moodle.ktu.edu/pluginfile.php/45753/mod_resource/content/5/13-python.pdf
2. <https://docs.python.org/3/>